

### 3. Dimension Reduction



# 你可能會遇到.....

搜集變數要越多越好嗎？

變數之間的相關性怎麼看？

變數和群體之間的關係怎麼看？

有沒有辦法可以縮減變數呢？

# Abstract

- 維度詛咒
- 生活中的降維
- PCA
- MDS
- 算法差異

# 維度詛咒

“

# Is Big Data A Miracle or a Curse?

# 維度詛咒

## (Curse of Dimensionality)

當維數提高時  
所需要的數據量通常隨著維數的提高  
而呈指數級增長  
可用數據就會變得很稀疏

“

數學的本質不是將簡單的事情變複雜  
而是將複雜的事物簡化

— Stan Gudder

# 降低維度方法



## 變數篩選



## 降維

減少變數的數量，儘量用最少的變數解釋最大的資訊

PCA (principal components analysis)

MDS (Multidimensional Scaling)

SVD (singular value decomposition)

t-SNE (t-distributed Stochastic Neighbor Embedding )

.....

# 生活中的降維

# 線性降維

彼此間存在高度正相關

國文(1)

英文(2)

數學(3)



線性降維

加權平均

$$12*1/6 + 13*2/6 + 15*3/6$$

代表申請大學門檻是否達成

# 非線性降維

彼此間存在高度正相關

身高

體重

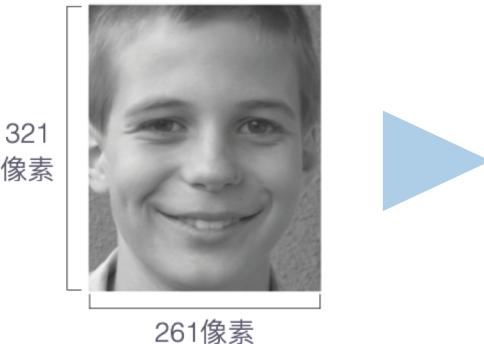
非線性降維

BMI(體重/身高平方)

用一維變數代表兩維變數

# 圖片降維 空間壓縮

一張圖片  $321 \times 261$  個數字



同一人 32 張圖片共 268 萬個數字



每一張圖片用4個數字表達， 每1個數字背後有1張圖片  
• 總共儲存數字: $4 \times 32 + 4 \times (321 \times 261) =$ 約33萬個數字



# PCA 主成份分析

# Principal Component Analysis

# PCA 目標

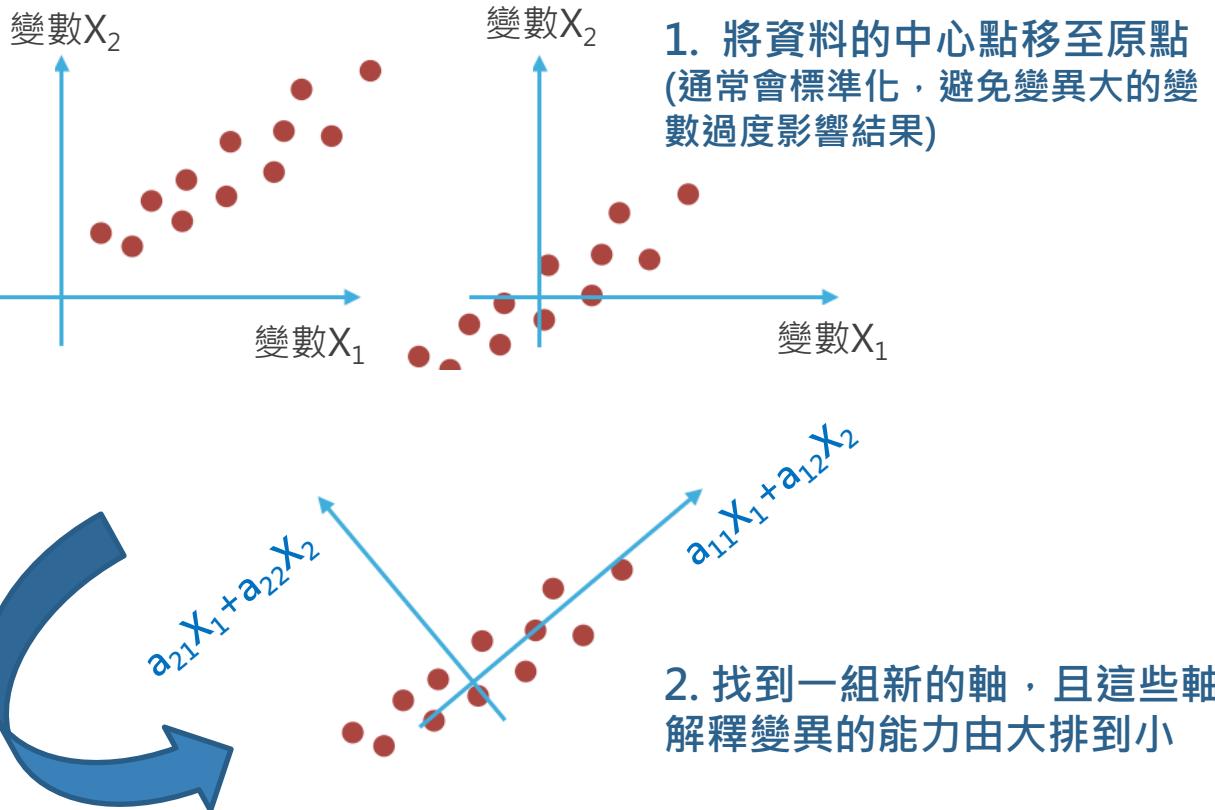
代表性  
保有原來變數的資訊

獨立性  
主成份間不能重疊

精簡性  
以少數主成份代替原來多個變數

# PCA

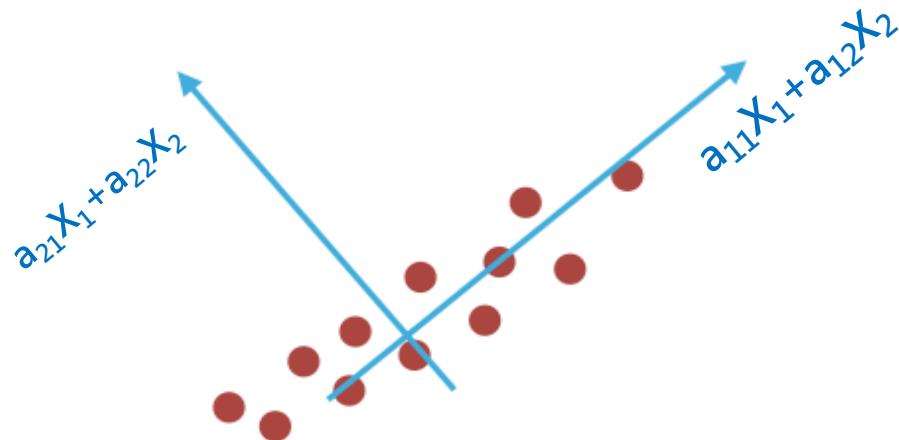
資料經過轉換過後，保留最大的變異



## 找出可有效表達資料的新變數(軸)

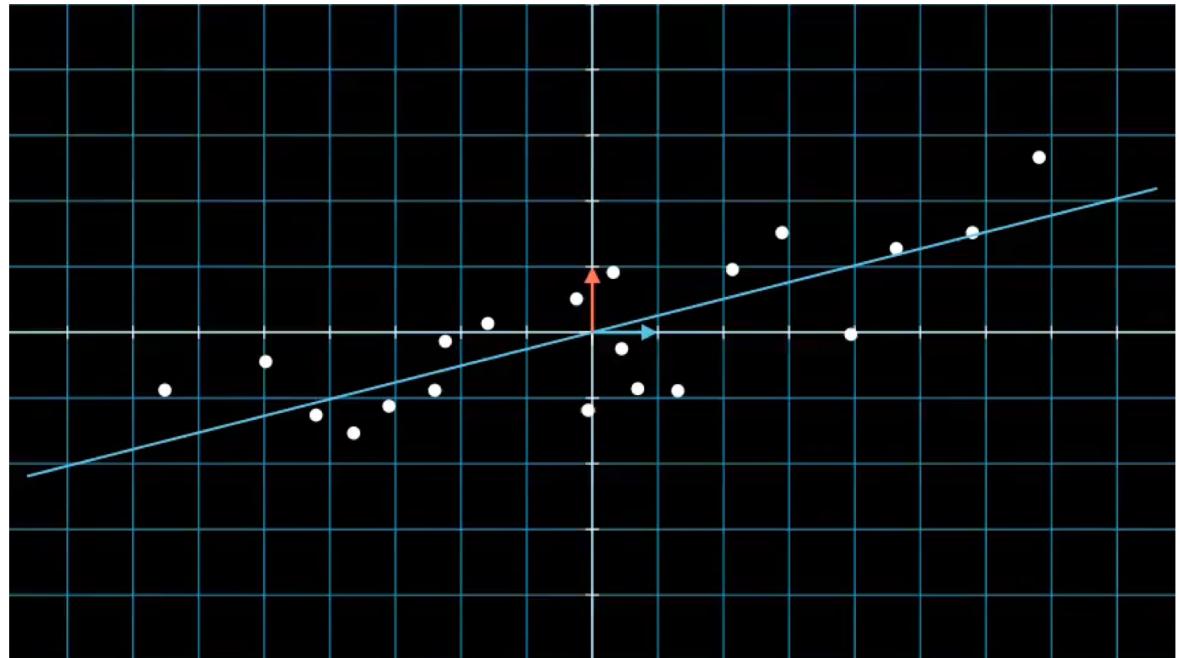
# PCA

- $X_1$ 與 $X_2$ 的線性組合
- 以捕捉最多的資料變異



- $X_1$ 與 $X_2$ 的線性組合
- 與第一個軸垂直(捕捉相異的資訊)
- 亦能捕捉更多的資料變異

x 軸並不一定得水平展開  
這世上的任何直線都能是你的 x 軸



# PCA

Input  
&  
Output

Input

Output



	變數1	...	n
個體1	V11	...	V1n
個體2	V21	...	V2n
...	...	...	...
個體m	Vm1	...	Vmn

1. 每個主成份都是原始變數的加權平均。
2. 主成份之間不相關。
3. 越前面的主成份解釋越多資料變異。
4. 拋棄較後面的主成份進行降維。

# PCA

變數 $X_1, \dots, X_p$ 透過「線性轉換」得到主成份 $F_1, \dots, F_i$

P 個 主 成 份

$$\boxed{F_1} = a_{11}X_1 + a_{12}X_2 + \dots + a_{1p}X_p$$
$$F_2 = a_{21}X_1 + a_{22}X_2 + \dots + a_{2p}X_p$$
$$F_i = a_{i1}X_1 + a_{i2}X_2 + \dots + a_{ip}X_p$$

1. 越前面的主成份解釋越多變異， $\text{Var}(F_1) \geq \text{Var}(F_2) \geq \dots \geq \text{Var}(F_i)$ 。
2. 主成份彼此不相關， $\text{Cor}(F_i, F_j) = 0 \cdot i \neq j$ 。
3. 每一個主成份的係數和為1。 $a_{i1} + a_{i2} + \dots + a_{ip} = 1$

估計  $a_{ip}$  達成兩大目標：  
極大化變異數與與保持主成份間不相關

$$\begin{aligned}Var(F_i) &= Var(a_{i1}X_1 + \cdots + a_{ip}X_p) \\&= a_{i1}^2 Var(X_1) + \cdots + a_{ip}^2 Var(X_p) \\&\quad + 2a_{i1}a_{i2}Cov(X_1, X_2) + \cdots + 2a_{ip-1}a_ipCov(X_{p-1}, X_p)\end{aligned}$$

- 極大化  $Var(F_i)$
- 限制式：保持第  $i$  個主成份與前  $(i-1)$  個主成份不相關

# PCA

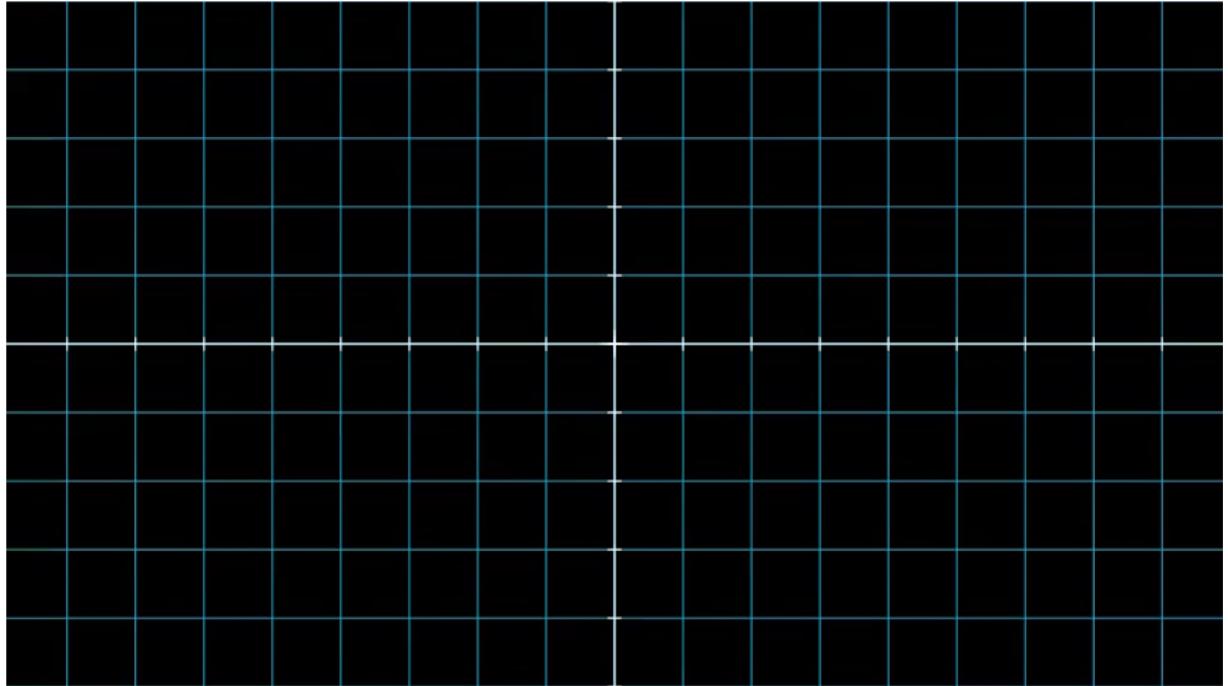
降維運算 :  $T$

還原該轉換的轉換 :  $T^{-1}$

$$RE = \sum_{i=1}^{n_{samples}} \left\| \vec{x}_i - T^{-1}T(\vec{x}_i) \right\|$$

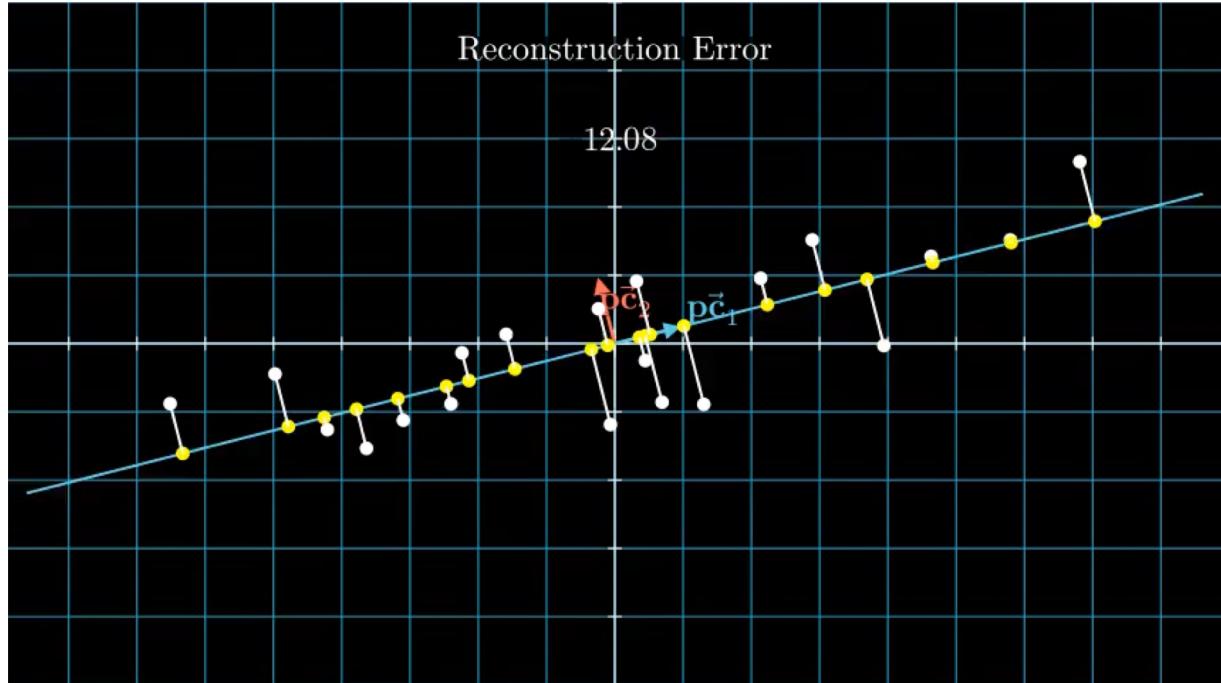
## 重建錯誤(Reconstruction Error, RE) :

將所有樣本從二維，降維後所得到的1維特徵 $L$ 後，再度還原回原2維空間。而還原後的結果  $X_{proj}$  跟原始數據  $X$  之間的距離總和就是 RE。RE 越低代表降維結果越成功，代表找出的新特徵  $L$  越具代表性。



# PCA

1. PCA找出來的主成分 $\text{pc}_1$ 是能找出最能代表數據  $X$  變異傾向的向量，它會使得投影後的 $\text{RE}_1$ 最小
2.  $\text{pc}_1$ 在最小化  $\text{RE}_1$ 的同時，也使得投影後的黃點分布最廣，這代表最大化新特徵  $L$ 的變異



如果將數據  $X$  投影到 PCA 中第二大的  $\text{pc}_2$  上，將得到最大的  $\text{RE}_1$ 。  
而因投影到  $\text{pc}_1$  能得到最小的  $\text{RE}_1$ ，這間接透露了  $\text{pc}_1$  跟  $\text{pc}_2$  互相垂直的事實  
( 兩者為正交 )。

# PCA 缺點

PCA 只能捕捉到變量之間線性的關聯

PCA 的計算要對平均中心平移，因此資料集中若有極端離群值發生會影響到估計的結果

大資料量會讓PCA無法很快的計算完畢

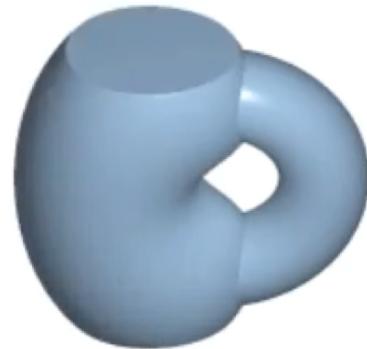
“

線性降維的核心精神  
是將原始數據拆解成更具代表性的主成分  
並以其作為新的基準  
由此獲得更能描述數據本質的新成分表徵

# MDS 多元尺度分析

# Multidimensional Scaling

# 流形 Manifold



# MDS

「一張圖，勝過千言萬語」

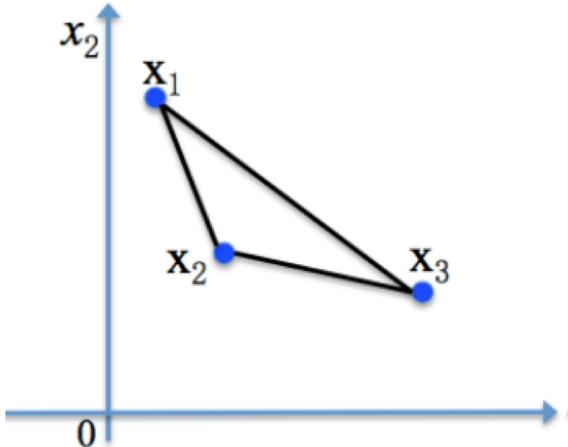
透過保持資料間歐式距離 ( Euclidean distance ) 關係，將高維對象非線性投影到低維空間，使得由降維所引起的任何變形達到最小

兩點間的歐式距離  $d(x, y)$  為：

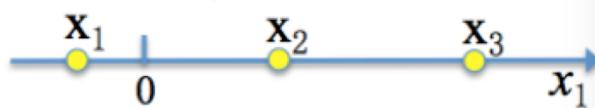
$$d(x, y) = \sqrt{(x - y)(x - y)^T}$$

是一種拓撲保留方法，用於降維外，亦可實現數據視覺化。

# MDS



樣本維度由兩維  
降成一維



# MDS

給定n個d維的樣本數據

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}$$



其中這n個樣本之間的歐式距離表示成以下矩陣

$$d(\mathbf{X}) = \begin{bmatrix} \delta_{11} & \delta_{12} & \cdots & \delta_{1n} \\ \delta_{21} & \delta_{22} & \cdots & \delta_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \delta_{n1} & \delta_{n2} & \cdots & \delta_{nn} \end{bmatrix} = \begin{bmatrix} 0 & ||\mathbf{x}_1 - \mathbf{x}_2|| & \cdots & ||\mathbf{x}_1 - \mathbf{x}_m|| \\ ||\mathbf{x}_2 - \mathbf{x}_1|| & 0 & \cdots & ||\mathbf{x}_2 - \mathbf{x}_m|| \\ \vdots & \vdots & \ddots & \vdots \\ ||\mathbf{x}_m - \mathbf{x}_1|| & ||\mathbf{x}_m - \mathbf{x}_2|| & \cdots & 0 \end{bmatrix}$$

$\sigma_{ij}(\mathbf{X}) = \delta_{ij}$  是樣本 i 和樣本 j 之間的歐式距離

# MDS

MDS的基本原理是在一個低維空間中，將n個物體鑲嵌到該空間中，使得彼此間的相似度盡可能保留。如果空間是2-3維，則可畫出n個物體的**視覺化結果**。

假設將n個樣本映射到新的p維空間中，映射成的矩陣形式如下：

$$\mathbf{Y} = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1p} \\ y_{21} & y_{22} & \cdots & y_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{np} \end{bmatrix}$$

其中p<d。MDS目的是最小化如下的目標函數。

$$\sigma(\mathbf{X}) = \sum_{i=1}^n \sum_{j=1}^n (\delta_{ij} - ||\mathbf{y}_i - \mathbf{y}_j||)^2$$

# 算法差異

# 算法差異



## PCA

關注維度本身，尋求最大化解釋變異

PCA不會保留數據的拓撲結構，本質上是捕捉變數間的線性關聯。因此，若變數具有非線性關係，用此方法即不適當



## MDS

關注縮放對象之間的關係

試圖保留數據的拓撲結構，它本質上是一種非線性變換，且不受異常值的影響，可檢測異常值

# 補充

# 為什麼在機器學習中，要把圖片做 flatten

許多傳統機器學習模型只能吃平坦的向量

模型	特徵要求
支持向量機 ( SVM )	需要一維向量
KMeans 聚類	需要一維向量
隨機森林 ( Random Forest )	需要一維向量
PCA ( 主成分分析 )	需要一維向量

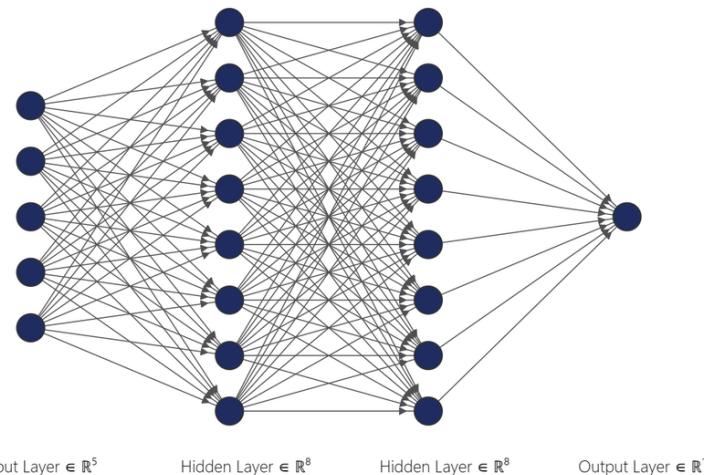
這些經典模型都只接受「一筆資料 → 一個向量」的形式。  
它們沒辦法直接處理「高度、寬度、RGB 通道」這種多維圖片。  
→ 圖片必須攤平成一條長向量，才能送進這些模型裡面！

# 為什麼在機器學習中，要把圖片做 flatten

## 2. 類神經網絡不一定需要一維向量

### (1) FCNN (Fully Connected Neural Network) :

- 只能處理一維向量，一開始就要 flatten，適合表格資料或數字特徵



# 為什麼在機器學習中，要把圖片做 flatten

## 2. 類神經網絡不一定需要一維向量

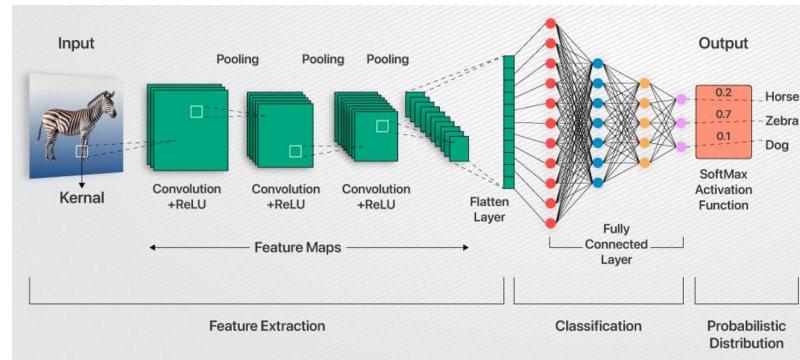
### (2) CNN

- **卷積神經網路 CNN**：CNN可以直接吃4維輸入 (batch\_size, height, width, channels)
- **全連接層 (Fully Connected Layer)**：即使在 CNN 中，到了後段要接 MLP 的時候還是要 flatten 一次！

#### ● 提示

CNN 要保留圖片的「局部結構」和「空間資訊」（像是  $3 \times 3$ 、 $5 \times 5$  卷積核掃過圖片）。

通常 CNN 是到 **卷積層和池化層** 結束後，在進入最後的 **Dense全連接層** 之前，才做 flatten。



# 為什麼在機器學習中，要把圖片做 flatten

## 2. 類神經網絡不一定需要一維向量

比較項目	FCNN	CNN
輸入	一維向量	保持圖片（多維結構）
特徵感知	完全失去空間結構	保留局部空間結構
優勢	簡單、快速	對圖片、空間結構超有效
缺點	對圖片處理能力差	複雜、需要設計卷積核

# flatten 前後： 資料特徵變了 什麼？

## 1. flatten 前 ( 原本是 3D 結構 : $height \times width \times channel$ )

- ✓ 保有圖片的空間資訊
  - ( 例：一個 pixel 左邊是什麼？上面是什麼？ )
- ✓ 局部特徵還存在
  - ( 像英雄的眼睛、鼻子、嘴巴，是局部連續特徵 )
- ✓ 適合給 CNN ( 卷積神經網路 ) 或其他空間感知模型

## 2. flatten 後 ( 變成 1D : 一條向量 )

- ✓ 打散了空間結構
  - 只剩下一堆數值，不知道哪個 pixel 原本在哪
- ✓ 局部鄰近關係消失
  - 原本左右相連的 pixel，在向量裡可能隔很遠
- ✓ 適合給 SVM、KMeans、PCA、全連接層 ( Dense ) 等不需要空間關係的模型

# 什麼時候該 flatten？什麼時候不要？

任務類型	是否需要 flatten ?	原因
傳統機器學習 ( SVM 、 KMeans 、 PCA )	要 flatten	因為模型只懂向量，不懂空間結構
Fully Connected Neural Network ( 全連接層神經網路 )	要 flatten	因為每個輸入神經元要獨立接收一個數字
CNN ( 卷積神經網路 ) 處理前面幾層	不要 flatten	CNN 需要保留局部圖形結構，才能卷積掃描
CNN 結束進入分類器時 ( 如 Dense 層 )	那時候才 flatten	要從 feature map 進 Dense 做分類

## ● 總結

如果你需要模型理解「這是張圖」→ 不要 flatten。  
如果你只需要模型看一堆特徵數字→ 就可以 flatten 。

# Thanks